TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Thanh Tuấn - 24122025

DỰ ĐOÁN GIÁ NHÀ VỚI HỒI QUY TUYẾN TÍNH

BÁO CÁO MÔN HỌC: PHƯƠNG PHÁP TOÁN CHO TRÍ TUỆ NHÂN TẠO
CHƯƠNG TRÌNH CHÍNH QUY

Tp. Hồ Chí Minh, tháng 04/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Thanh Tuấn - 24122025

DỰ ĐOÁN GIÁ NHÀ VỚI HỒI QUY TUYẾN TÍNH

BÁO CÁO MÔN HỌC: PHƯƠNG PHÁP TOÁN CHO TRÍ TUỆ NHÂN TẠO
CHƯƠNG TRÌNH CHÍNH QUY

GIÁO VIÊN HƯỚNG DẪN

TS. Cấn Trần Thành Trung

TS. Đỗ Đức Hào

Ths. Nguyễn Ngọc Toàn

CN. Trần Hoàng Quân

Tp. Hồ Chí Minh, tháng 04/2026

Mục lục

Mục lục **i**

1 Giới thiệu bài toán **1**

2 Cơ sở lý thuyết và Thuật toán **2**

2.1 Mô hình Hồi quy tuyến tính (Linear Regression) 2

2.2 Hàm mất mát 3

2.3 Thuật toán Gradient Descent 3

2.4 Gradient của hàm mất mát MSE 4

2.5 Tính tối ưu của nghiệm 6

2.6 Thang đo đánh giá MAE 7

3 Phân tích khám phá dữ liệu (EDA) **8**

3.1 Khám phá thông tin cơ bản của dữ liệu 8

3.2 Thống kê mô tả cho các đặc trưng số 10

3.3 Phân tích phân phối của biến mục tiêu SalePrice 11

3.4 Biểu đồ histogram của các đặc trưng số 13

3.5 Heatmap thể hiện tương quan giữa các đặc trưng số 14

3.6 Biểu đồ scatter 15

3.7 Biểu đồ hộp 18

4 Xây dựng và đánh giá mô hình **22**

4.1 Xây dựng mô hình sử dụng toàn bộ đặc trưng đầu vào . . 22

4.1.1 Lý do lựa chọn mô hình 22

4.1.2 Tiền xử lý dữ liệu 22

4.1.3 Kết quả 24

4.1.4 Nhận xét 24

4.2 Xây dựng mô hình với một đặc trưng và tìm mô hình tốt nhất 25

4.2.1 Lý do lựa chọn mô hình 25

4.2.2 Thiết lập thực nghiệm 25
4.2.3 Kết quả trên tập Cross-Validation 25
4.2.4 Lựa chọn và kiểm tra 26
4.2.5 Nhận xét 26
4.3 Tự thiết kế các mô hình đặc trưng và tìm mô hình tốt nhất 26
4.3.1 Phương án 1: Tạo đặc trưng mới 26
4.3.2 Phương án 2: Chọn tập con đặc trưng 27
4.3.3 Phương án 3: Thực hiện mã hóa lại các đặc trưng phân loại 28
4.3.4 Phương án 4: Biến đổi log cho các đặc trưng bị lệch 29
4.3.5 Phương án 5: Kết hợp biến đổi log + chọn tập con đặc trưng 30
4.3.6 Lựa chọn và kiểm tra 31
4.3.7 Nhận xét 31

5 Kết luận **33**

Tài liệu tham khảo **35**

Danh sách hình

3.1 Phân tích phân phối của biến mục tiêu SalePrice 12
3.2 Biểu đồ histogram của các đặc trưng số trong tập huấn luyện 13
3.3 Biểu đồ heatmap thể hiện ma trận tương quan giữa các đặc trưng số và biến mục tiêu **SalePrice** 14
3.4 Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số liên tục và biến mục tiêu **SalePrice** 16
3.5 Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số rời rạc và biến mục tiêu **SalePrice** 17
3.6 Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số liên tục bị lạm phát 0 và biến mục tiêu **SalePrice** 18
3.7 Biểu đồ hộp của đặc trưng **OverallQual** 20
3.8 Biểu đồ hộp của đặc trưng **BsmtFinType2** 21

Danh sách bảng

4.1 So sánh hiệu suất của các đặc trưng trên tập validation . . 25
4.2 So sánh hiệu suất của các phương án trên tập validation . 31

Chương 1

Giới thiệu bài toán

Trong lĩnh vực bất động sản, việc định giá chính xác giá trị nhà ở đóng vai trò quan trọng đối với cả người mua, người bán và các nhà đầu tư. Mục tiêu cốt lõi của bài thực hành này là xây dựng các mô hình hồi quy tuyến tính (Linear Regression) để dự đoán giá bán nhà dựa trên các đặc điểm của ngôi nhà như diện tích, số phòng ngủ, vị trí, và nhiều yếu tố khác.

Bộ dữ liệu được sử dụng trong bài thực hành này mô tả nhiều đặc trưng của ngôi nhà như:

- Thông tin cơ bản: **MSSubClass, MSZoning, Neighborhood, HouseStyle**.
- Diện tích và kích thước: **LotArea, LotFrontage, GrLivArea, TotalBsmtSF, GarageArea**.
- Chất lượng và tình trạng: **OverallQual, OverallCond, KitchenQual, ExterQual**.
- Thời gian xây dựng và cải tạo: **YearBuilt, YearRemodAdd, GarageYrBlt, YrSold**.

Nhiệm vụ trọng tâm là dự đoán chính xác biến mục tiêu **SalePrice** (giá bán cuối cùng của căn nhà). Để đạt được mục tiêu này, bài làm yêu cầu thực hiện phân tích khám phá dữ liệu (EDA), tiền xử lý và xây dựng các phương án mô hình khác nhau từ tập huấn luyện (train.csv). Hiệu năng của các mô hình cuối cùng sẽ được đánh giá trên tập kiểm tra (test.csv) thông qua độ đo sai số tuyệt đối trung bình (MAE).

Chương 2

Cơ sở lý thuyết và Thuật toán

2.1 Mô hình Hồi quy tuyến tính (Linear Regression)

Hồi quy tuyến tính là một phương pháp thống kê được sử dụng để mô hình hóa mối quan hệ giữa một biến phụ thuộc (biến mục tiêu) và một hoặc nhiều biến độc lập (đặc trưng). Mục tiêu của hồi quy tuyến tính là tìm ra một hàm số tuyến tính có thể dự đoán giá trị của biến phụ thuộc dựa trên các giá trị của các biến độc lập.

Với tập dữ liệu có n đặc trưng, mô hình hồi quy tuyến tính có thể được biểu diễn dưới dạng công thức sau:

$$\hat{y} = \omega_1 x_1 + \omega_2 x_2 + ... + \omega_n x_n + b$$

Trong đó:

- $\hat{y}$ là giá trị dự đoán của biến phụ thuộc.
- ω_i là hệ số hồi quy (coefficient) tương ứng với đặc trưng x_i.
- b là hệ số chệch (intercept) của mô hình.
- x_i là giá trị của đặc trưng thứ i.
- n là số lượng đặc trưng trong mô hình.

Để thuận tiện cho việc tính toán, ta có thể biểu diễn b thành một trọng số hồi quy ω_0 tương ứng với một đặc trưng giả x_0 luôn có giá trị bằng 1. Khi đó, công thức của mô hình hồi quy tuyến tính có thể được viết lại như sau:

$$\hat{y} = \omega_0 x_0 + \omega_1 x_1 + \omega_2 x_2 + ... + \omega_n x_n = \sum_{i=0}^{n} \omega_i x_i$$

Mục tiêu của việc huấn luyện mô hình hồi quy tuyến tính là tìm ra các hệ số ω_i sao cho hàm số tuyến tính có thể dự đoán giá trị của biến phụ thuộc một cách chính xác nhất.

2.2 Hàm mất mát

Để đánh giá hiệu suất của mô hình hồi quy tuyến tính, chúng ta sử dụng một hàm mất mát (loss function) để đo lường sự khác biệt giữa giá trị dự đoán $\hat{y}$ và giá trị thực tế y. Có nhiều loại hàm mất mát khác nhau, trong thực tế đa phần các bài toán hồi quy tuyến tính thường sử dụng hàm mất mát bình phương trung bình (Mean Squared Error - MSE),

Công thức của hàm mất mát MSE được định nghĩa như sau:

$$MSE = L(\hat{Y}, Y) = \frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2$$

2.3 Thuật toán Gradient Descent

Để tối ưu hóa các hệ số ω_i của mô hình hồi quy tuyến tính, một trong những thuật toán phổ biến nhất được sử dụng là thuật toán Gradient Descent. Thuật toán này hoạt động bằng cách tính toán gradient của hàm mất mát đối với các hệ số ω_i và cập nhật các hệ số này theo hướng giảm dần của hàm mất mát.

Công thức cập nhật các hệ số ω_i trong thuật toán Gradient Descent được định nghĩa như sau:

$$\omega_i := \omega_i - \alpha\frac{\partial MSE}{\partial \omega_i}$$

Trong đó:

- ω_i là hệ số hồi quy thứ i cần được cập nhật.
- α là tốc độ học (learning rate), một siêu tham số dùng để điều chỉnh kích thước bước cập nhật của các hệ số.
- $\frac{\partial MSE}{\partial \omega_i}$ là gradient của hàm mất mát MSE đối với hệ số ω_i.

Gradient Descent sẽ tiếp tục cập nhật các hệ số ω_i cho đến khi hội tụ, tức là khi sự thay đổi của hàm mất mát giữa các lần cập nhật trở nên rất nhỏ hoặc đạt đến một ngưỡng nhất định.

2.4 Gradient của hàm mất mát MSE

Để thuận tiện cho việc tính toán, ta thống nhất một số ký hiệu như sau:

- n là số lượng đặc trưng trong mô hình.
- m là số lượng mẫu trong tập dữ liệu.
- Một điểm dữ liệu được biểu diễn dưới dạng vector cột $\vec{x} = (1, x_1, x_2, ..., x_n)^T$, trong đó x_j là giá trị của đặc trưng thứ j.
- $\vec{x_i}$ là vector cột biểu diễn điểm dữ liệu thứ i, trong đó x_{ij} là giá trị của đặc trưng thứ j của điểm dữ liệu thứ i.
- Vector hệ số hồi quy $\vec{\omega} = (\omega_0, \omega_1, ..., \omega_n)^T$ là một vector cột chứa các hệ số hồi quy tương ứng với các đặc trưng.
- y_i là giá trị thực tế của biến phụ thuộc cho mẫu thứ i.
- X là ma trận đặc trưng có kích thước $(n+1) \times m$, trong đó hàng thứ i của ma trận là vector $\vec{x_i}$ biểu diễn điểm dữ liệu thứ i.
- Y là ma trận chứa các giá trị thực tế của biến phụ thuộc, có kích thước $m \times 1$.

Khi đó,

$$\hat{y}_i = \sum_{j=0}^{n} \omega_j x_{ij} = \vec{\omega} \cdot \vec{x_i}$$

là giá trị dự đoán của mô hình cho điểm dữ liệu thứ i. Từ đó ta có thể xây dựng được ma trận dự đoán $\hat{Y}$ có kích thước $m \times 1$ như sau:

$$\hat{Y} = X^T \vec{\omega}$$

Hàm mất mát MSE được định nghĩa như sau:

$$MSE = L(\hat{Y}, Y) = \frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2 = \frac{1}{2m}\sum_{i=1}^{m}[\vec{\omega}\cdot\vec{x}_i - y_i]^2$$

Ta có:

$$L(\hat{Y}, Y) = f(\hat{Y}) = f(\hat{y}_1, \hat{y}_2, \cdots, \hat{y}_m)$$

$$\hat{y}_i = \vec{\omega}\cdot\vec{x}_i = \sum_{j=0}^{n}\omega_j x_{ij} = g(\vec{\omega}) = g(x_0, x_1, x_2, \cdots, x_n)$$

Để tính gradient của hàm mất mát MSE đối với hệ số ω_j và intercept b, ta sử dụng quy tắc chuỗi (chain rule) trong giải tích đa biến như sau:

$$\frac{\partial L}{\partial \omega_j} = \sum_{i=1}^{m}\frac{\partial L}{\partial \hat{y}_i}\cdot\frac{\partial \hat{y}_i}{\partial \omega_j} = \sum_{i=1}^{m}\frac{\partial L}{\partial \hat{y}_i}\cdot x_{ij}$$

Với hàm mát mát là MSE, ta có:

$$L(\hat{Y}, Y) = \frac{1}{2m}\sum_{i=1}^{m}(\hat{y}_i - y_i)^2$$

Suy ra:

$$\frac{\partial L}{\partial \hat{y}_i} = \frac{1}{m}(\hat{y}_i - y_i)$$

Từ đó, ta có thể tính được gradient của hàm mất mát MSE đối với hệ số ω_j như sau:

$$\frac{\partial L}{\partial \omega_j} = \sum_{i=1}^{m}\frac{1}{m}(\hat{y}_i - y_i)\cdot x_{ij} = \frac{1}{m}\sum_{i=1}^{m}(\hat{y}_i - y_i)\cdot x_{ij}$$

Suy ra, vector gradient của hàm mất mát MSE đối với vector hệ số hồi quy $\vec{\omega}$ có thể được biểu diễn dưới dạng ma trận như sau:

$$\nabla_{\vec{\omega}} L = \begin{pmatrix} \frac{\partial L}{\partial \omega_0} \\ \frac{\partial L}{\partial \omega_1} \\ \vdots \\ \frac{\partial L}{\partial \omega_n} \end{pmatrix} = \begin{pmatrix} \frac{1}{m}\sum_{i=1}^{m}(\hat{y}_i - y_i)\cdot x_{i0} \\ \frac{1}{m}\sum_{i=1}^{m}(\hat{y}_i - y_i)\cdot x_{i1} \\ \vdots \\ \frac{1}{m}\sum_{i=1}^{m}(\hat{y}_i - y_i)\cdot x_{in} \end{pmatrix} = \frac{1}{m}X(\hat{Y} - Y)$$

Để tìm được tọa độ của điểm cực trị của hàm mất mát MSE, ta cần giải hệ phương trình $\nabla_{\vec{\omega}} L = 0$.

$$\begin{aligned}
\nabla_{\vec{\omega}} L &= 0 \\
\Leftrightarrow \frac{1}{m} X(\hat{Y} - Y) &= 0 \\
\Leftrightarrow X(\hat{Y} - Y) &= 0 \\
\Leftrightarrow X\hat{Y} &= XY \\
\Leftrightarrow XX^T\vec{\omega} &= XY \\
\Leftrightarrow \vec{\omega} &= (XX^T)^{-1}XY
\end{aligned}$$

2.5 Tính tối ưu của nghiệm

Để khẳng định nghiệm $\vec{\omega} = (XX^T)^{-1}XY$ tìm được là điểm cực tiểu toàn cục của hàm mất mát MSE, ta xem xét đạo hàm bậc hai (Ma trận Hessian) của hàm L:

$$\nabla^2_{\vec{\omega}} L = \frac{\partial}{\partial \vec{\omega}}(\nabla_{\vec{\omega}} L) = \frac{\partial}{\partial \vec{\omega}}\left[\frac{1}{m} X(X^T\vec{\omega} - Y)\right] = \frac{1}{m} XX^T$$

Ta nhận thấy rằng:

- Ma trận $H = \frac{1}{m} XX^T$ là một ma trận đối xứng và nửa xác định dương (Positive Semi-definite), vì với mọi vector $\vec{v} \neq 0$, ta luôn có:

$$\vec{v}^T(XX^T)\vec{v} = (X^T\vec{v})^T(X^T\vec{v}) = ||X^T\vec{v}||^2 \geq 0$$

- Do ma trận Hessian luôn không âm, hàm mất mát MSE là một hàm lồi (Convex Function) trên toàn bộ không gian của $\vec{\omega}$.

Đối với một hàm lồi, mọi điểm cực trị đều là điểm cực tiểu toàn cục. Do đó, nghiệm $\vec{\omega} = (XX^T)^{-1}XY$ tìm được từ việc giải hệ phương trình $\nabla_{\vec{\omega}} L = 0$ là điểm cực tiểu toàn cục của hàm mất mát MSE.

Dựa vào đặc điểm của bộ dataset trong bài lab này (số đặc trưng ít, số lượng mẫu nhỏ,...) mà ta sẽ phân tích ngay dưới đây, việc sử dụng công thức đóng cho các hệ số hồi quy thay vì sử dụng thuật toán Gradient

Descent sẽ giúp ta tìm được nghiệm tối ưu một cách chính xác và nhanh chóng, đồng thời tránh được các vấn đề liên quan đến việc lựa chọn tốc độ học (learning rate) và hội tụ của thuật toán Gradient Descent.

2.6 Thang đo đánh giá MAE

Để đánh giá hiệu suất của mô hình hồi quy tuyến tính, chúng ta sử dụng một thang đo đánh giá phổ biến là sai số tuyệt đối trung bình (Mean Absolute Error - MAE). MAE được định nghĩa như sau:

$$MAE = \frac{1}{m}\sum_{i=1}^{m}|\hat{y}_i - y_i|$$

MAE đo lường trung bình của các sai số tuyệt đối giữa giá trị dự đoán $\hat{y}_i$ và giá trị thực tế y_i. MAE có thứ nguyên giống với giá trị dự đoán và giá trị thực tế, do đó nó dễ hiểu và trực quan hơn so với các thang đo khác như MSE.

Cụ thể, trong bài toán này ta cần dự đoán giá bán nhà, khi đó MAE sẽ cho biết được độ chênh lệch trung bình trong giá bán của tập các căn nhà. Điều này dễ dàng để hiểu và giải thích cho khách hàng, đặc biệt là khi so sánh với các thang đo khác như MSE, có thứ nguyên là bình phương giá tiền vốn không có ý nghĩa trực quan đối với người mua nhà.

Chương 3

Phân tích khám phá dữ liệu (EDA)

Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) là một bước quan trọng trong quá trình xây dựng mô hình học máy, giúp chúng ta hiểu rõ hơn về dữ liệu, phát hiện các mẫu, mối quan hệ và các vấn đề tiềm ẩn trong dữ liệu.

3.1 Khám phá thông tin cơ bản của dữ liệu

```python
# In ra so dong, so cot, ten cot, kieu du lieu
print(f"So dong, cot tren tap train: {X_train_full.shape[0]}, {X_train_full
    .shape[1]}")
print(f"Ten cac cot, kieu du lieu:")
X_train_full.info()
```

Output của đoạn code trên:

```
Số dòng, cột trên tập train: 1460, 79
Tên các cột, kiểu dữ liệu:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 79 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
...
dtypes: float64(3), int64(33), object(43)
```

Qua đó ta có cái nhìn tổng quan về bộ dữ liệu:

- Bộ dữ liệu huấn luyện có 1460 mẫu và 79 đặc trưng.

- Có 43 đặc trưng có kiểu dữ liệu là object (thường là các đặc trưng phân loại)
- 33 đặc trưng có kiểu dữ liệu là int64 (các đặc trưng số nguyên)
- 3 đặc trưng có kiểu dữ liệu là float64 (các đặc trưng số thực).

Tiếp theo ta sẽ kiểm tra số lượng giá trị thiếu trong từng cột của tập dữ liệu huấn luyện. Việc này giúp chúng ta xác định được các đặc trưng nào có nhiều giá trị thiếu và cần được xử lý trước khi xây dựng mô hình.

```
# Tinh toan so luong va ti le phan tram
missing_counts = X_train_full.isnull().sum()
missing_percents = (missing_counts / len(X_train_full)) * 100

missing_df = pd.concat([missing_counts, missing_percents], axis=1, keys=['So luong', 'Phan tram (%)'])
missing_report = missing_df[missing_df['So luong'] > 0].sort_values(by='So luong', ascending=False)

print(missing_report)
```

```
               Số lượng  Phần trăm (%)
PoolQC             1453      99.520548
MiscFeature        1406      96.301370
Alley              1369      93.767123
Fence              1179      80.753425
MasVnrType          872      59.726027
FireplaceQu         690      47.260274
LotFrontage         259      17.739726
GarageType           81       5.547945
GarageYrBlt          81       5.547945
GarageFinish         81       5.547945
GarageQual           81       5.547945
GarageCond           81       5.547945
BsmtExposure         38       2.602740
BsmtFinType2         38       2.602740
BsmtQual             37       2.534247
BsmtCond             37       2.534247
```

```
BsmtFinType1        37        2.534247
MasVnrArea           8        0.547945
Electrical           1        0.068493
```

Có những đặc trưng có số lượng giá trị và tỉ lệ thiếu rất lớn như PoolQC, MiscFeature, Alley, Fence, MasVnrType, FireplaceQu. Những đặc trưng này có thể không cung cấp nhiều thông tin hữu ích cho mô hình và có thể được loại bỏ hoặc xử lý đặc biệt trong bước tiền xử lý dữ liệu. Các đặc trưng còn lại có số lượng giá trị bị thiếu ít hơn, đủ để đặc trưng có thể cung cấp thông tin cho mô hình.

Để xử lý các giá trị thiếu này, đối với đặc trưng số, ta có thể lựa chọn điền vào giá trị trung vị (median) hoặc giá trị trung bình (mean), tùy thuộc vào phân phối của dữ liệu. Đối với đặc trưng phân loại, ta có thể điền vào giá trị phổ biến nhất (mode) hoặc tạo một hạng mục mới để biểu thị giá trị thiếu.

Với bộ dữ liệu này, ta sẽ áp dụng phương pháp điền giá trị trung vị cho các đặc trưng số và phương pháp điền giá trị phổ biến nhất cho các đặc trưng phân loại. Phương pháp này đảm bảo rằng giá trị điền vào không bị ảnh hưởng bởi các giá trị ngoại lai (như giá trị trung bình), đồng thời giữ lại được phân phối của dữ liệu.

3.2 Thống kê mô tả cho các đặc trưng số

```python
# Thong ke mo ta cho cac dac trung so
print("Thong ke mo ta cho cac dac trung so:")
X_train_full.describe()
```

Các giá trị thống kê được thực hiện bao gồm:

- count: Số lượng giá trị không thiếu trong mỗi cột.
- mean: Giá trị trung bình của mỗi cột.
- std: Độ lệch chuẩn, đo lường sự phân tán của dữ liệu xung quanh giá trị trung bình.
- min: Giá trị nhỏ nhất trong mỗi cột.

- 25%: Giá trị phần tư thứ nhất (Q1), là giá trị mà 25% dữ liệu nằm dưới nó.
- 50%: Giá trị phần tư thứ hai (Q2) hay còn gọi là median, là giá trị mà 50% dữ liệu nằm dưới nó.
- 75%: Giá trị phần tư thứ ba (Q3), là giá trị mà 75% dữ liệu nằm dưới nó.
- max: Giá trị lớn nhất trong mỗi cột.

3.3 Phân tích phân phối của biến mục tiêu SalePrice

```
# Phan tich phan phoi cua bien muc tieu SalePrice
print("Phan phoi cua bien muc tieu SalePrice:")

fix, ax = plt.subplots(1, 2, figsize=(10, 6))
sns.histplot(y_train_full, ax=ax[0])
ax[0].tick_params(axis='x', rotation=45)
ax[1] = stats.probplot(y_train_full, plot=plt)
plt.tight_layout()
plt.show()

# Skewness cua bien muc tieu
print(f"Skewness cua bien muc tieu: {y_train_full.skew()}")
```

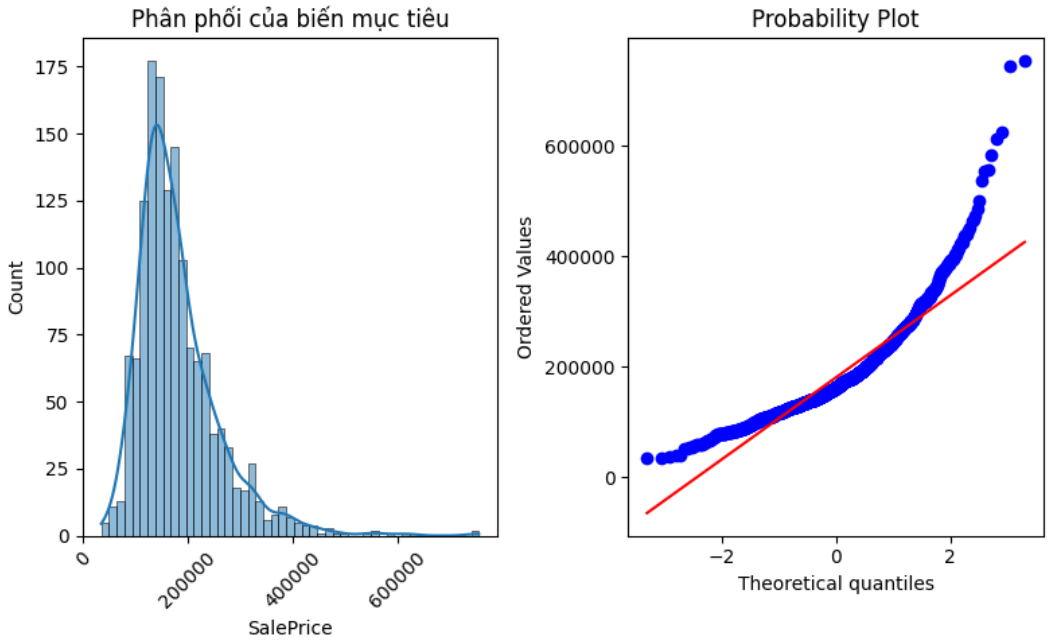

Hình 3.1: Phân tích phân phối của biến mục tiêu SalePrice

```
Skewness của biến mục tiêu: 1.8828757597682129
```

Chỉ số skewness là một thang đo về độ lệch của phân phối dữ liệu so với phân phối chuẩn. Nếu giá trị skewness dương, phân phối có đuôi dài về phía bên phải (right-skewed), nếu giá trị skewness âm, phân phối có đuôi dài về phía bên trái (left-skewed), và nếu giá trị skewness gần bằng 0, phân phối gần giống với phân phối chuẩn.

Trong trường hợp này, giá trị skewness của biến mục tiêu **SalePrice** là **1.883** cho thấy rằng phân phối của **SalePrice** có đuôi dài về phía bên phải, tức là có nhiều giá trị lớn hơn trung bình so với giá trị nhỏ hơn trung bình. Điều này có thể ảnh hưởng đến hiệu suất của một số mô hình học máy, đặc biệt là các mô hình tuyến tính, và có thể cần được xử lý bằng cách áp dụng các kỹ thuật biến đổi dữ liệu như log transformation để làm giảm độ lệch của phân phối.

Đồ thị histogram cho thấy rằng phần lớn các giá trị của **SalePrice** tập trung ở mức giá thấp hơn, trong khi có một số ít giá trị lớn hơn tạo thành đuôi dài về phía bên phải của phân phối.

Đồ thị Q-Q (Quantile-Quantile plot) biểu diễn các giá trị phân vị của dữ liệu thực tế so với các giá trị phân vị của phân phối chuẩn. Nếu các điểm dữ liệu nằm gần đường thẳng, điều đó cho thấy rằng dữ liệu tuân theo

phân phối chuẩn. Tuy nhiên, đồ thị Q-Q plot của biến mục tiêu **SalePrice** cho thấy rằng các điểm dữ liệu không hoàn toàn nằm trên đường thẳng, đặc biệt là ở phần đuôi bên phải, điều này cũng cho thấy rằng phân phối của **SalePrice** không hoàn toàn tuân theo phân phối chuẩn và có sự lệch phải.

3.4 Biểu đồ histogram của các đặc trưng số

```
# Ve bieu do histogram
X_train_full.hist(figsize=(20, 12), bins=30)
plt.tight_layout()
plt.show()
```

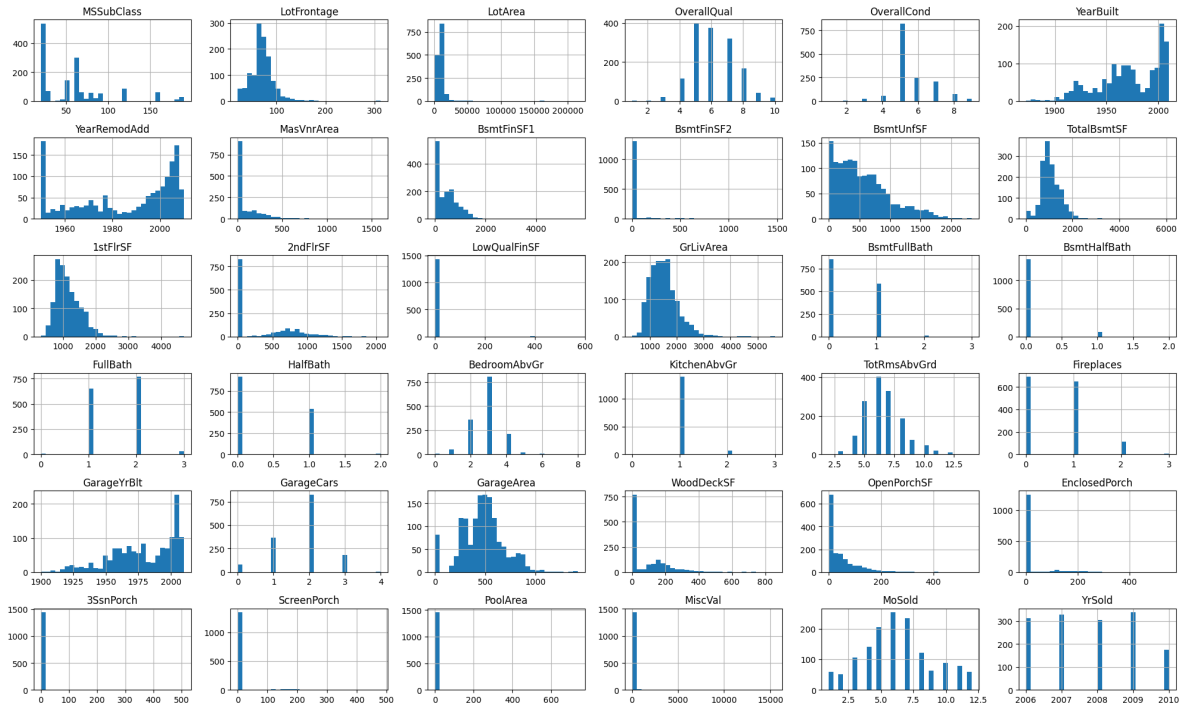

Hình 3.2: Biểu đồ histogram của các đặc trưng số trong tập huấn luyện

Từ biểu đồ histogram, ta có thể quan sát được phân phối của các đặc trưng số trong tập huấn luyện. Một số đặc trưng có phân phối gần giống với phân phối chuẩn (như **OverallQual**, **MoSold**,...), trong khi một số khác có phân phối lệch phải hoặc lệch trái hoặc không đều. Những đặc trưng có phân phối lệch có thể cần được xử lý bằng các kỹ thuật khác nhau để cải thiện hiệu suất của mô hình học máy, đặc biệt là các mô hình tuyến tính.

3.5 Heatmap thể hiện tương quan giữa các đặc trưng số

```
# Ve heatmap
new_df = pd.concat([X_train_full.select_dtypes(include="number"),
    y_train_full], axis=1)
corr = new_df.corr()
high_corr = corr[abs(corr) > 0.5]
plt.figure(figsize=(20, 12))
sns.heatmap(high_corr, annot=True, cmap='coolwarm', vmin=0.5, vmax=1)
plt.show()
```

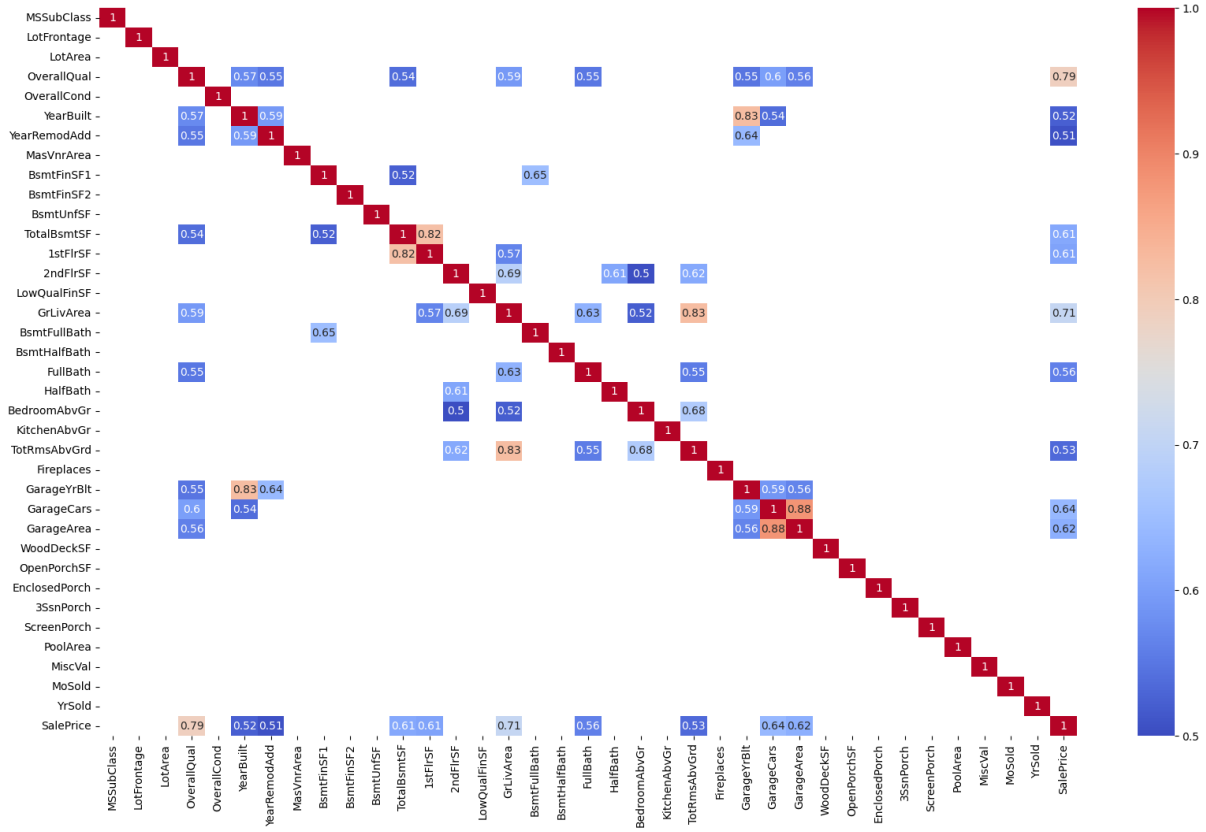

Hình 3.3: Biểu đồ heatmap thể hiện ma trận tương quan giữa các đặc trưng số và biến mục tiêu **SalePrice**

Biểu đồ heatmap thể hiện ma trận tương quan giữa các đặc trưng số và biến mục tiêu **SalePrice**. Các ô màu càng ấm biểu thị mức độ tương quan càng lớn theo chiều dương.

Dựa vào biểu đồ heatmap, ta có thể nhận thấy rằng một số đặc trưng số có tương quan mạnh với biến mục tiêu **SalePrice**, như **OverallQual**,

GrLivArea, **GarageCars**,... Những đặc trưng này có thể đóng vai trò quan trọng trong việc dự đoán giá nhà và nên được xem xét kỹ lưỡng trong quá trình xây dựng mô hình học máy.

Đồng thời, có những cặp đặc trưng số có tương quan mạnh với nhau, như **GarageCars** và **GarageArea**, điều này có thể dẫn đến vấn đề đa cộng tuyến (multicollinearity) khi xây dựng mô hình tuyến tính. Trong trường hợp này, ta có thể xem xét loại bỏ một trong hai đặc trưng hoặc sử dụng các kỹ thuật giảm chiều dữ liệu để giải quyết vấn đề này.

3.6 Biểu đồ scatter

Khi biểu diễn dữ liệu số lên đồ thị scatter, ta thấy rằng có thể phân loại các đặc trưng số thành hai loại chính: Dữ liệu số liên tục và dữ liệu số rời rạc. Dữ liệu số liên tục là những đặc trưng có giá trị có thể nằm trong một khoảng liên tục, như **YearBuilt**, **GrLivArea**,... Trong khi đó, dữ liệu số rời rạc là những đặc trưng có giá trị chỉ có thể nhận một số lượng hữu hạn các giá trị, như **OverallQual**, **GarageCars**,...

```
# Vi du mot dac trung so lien tuc

sns.scatterplot(x=X_train_full['YearBuilt'], y=y_train_full, alpha=0.5,
    color='teal')
plt.title('YearBuilt vs SalePrice')
plt.xlabel('YearBuilt')
plt.ylabel('SalePrice')
plt.show()
```

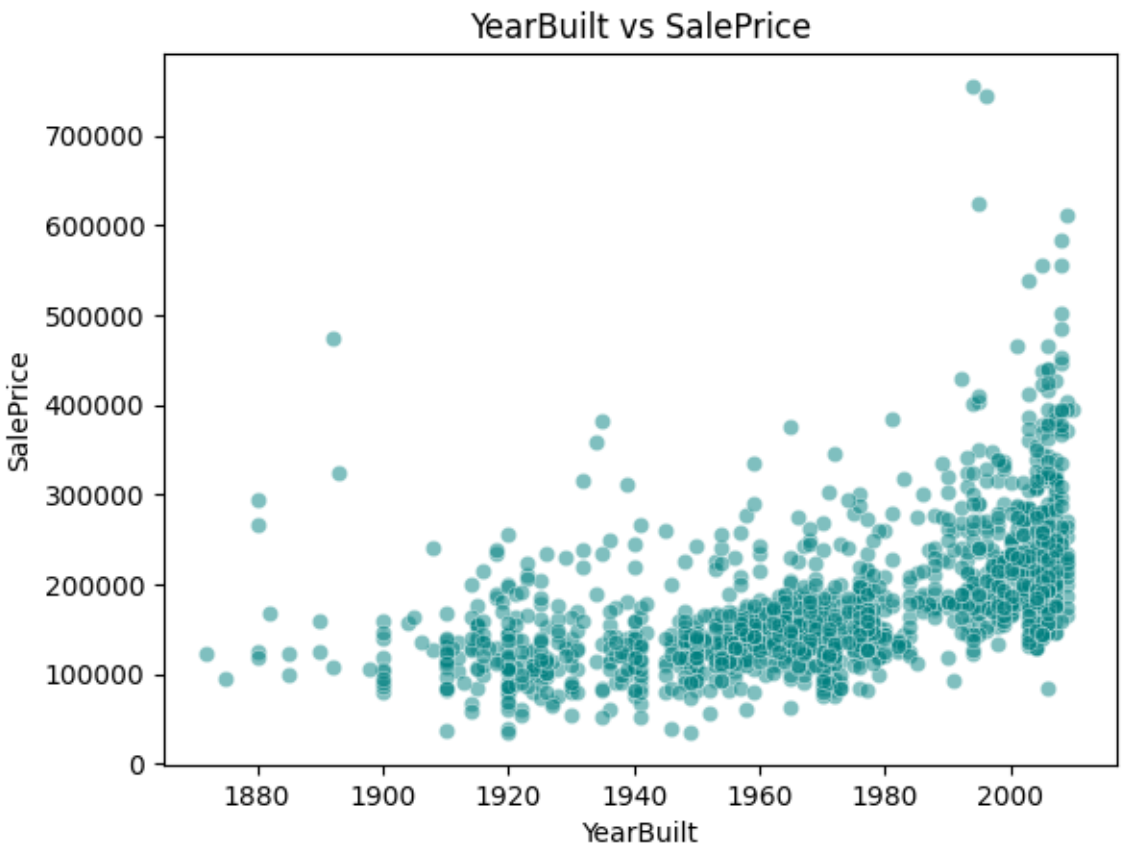

Hình 3.4: Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số liên tục và biến mục tiêu **SalePrice**

```
# Vi du mot dac trung so roi rac

sns.scatterplot(x=X_train_full['OverallQual'], y=y_train_full, alpha=0.5,
    color='teal')
plt.title('OverallQual vs SalePrice')
plt.xlabel('OverallQual')
plt.ylabel('SalePrice')
plt.show()
```

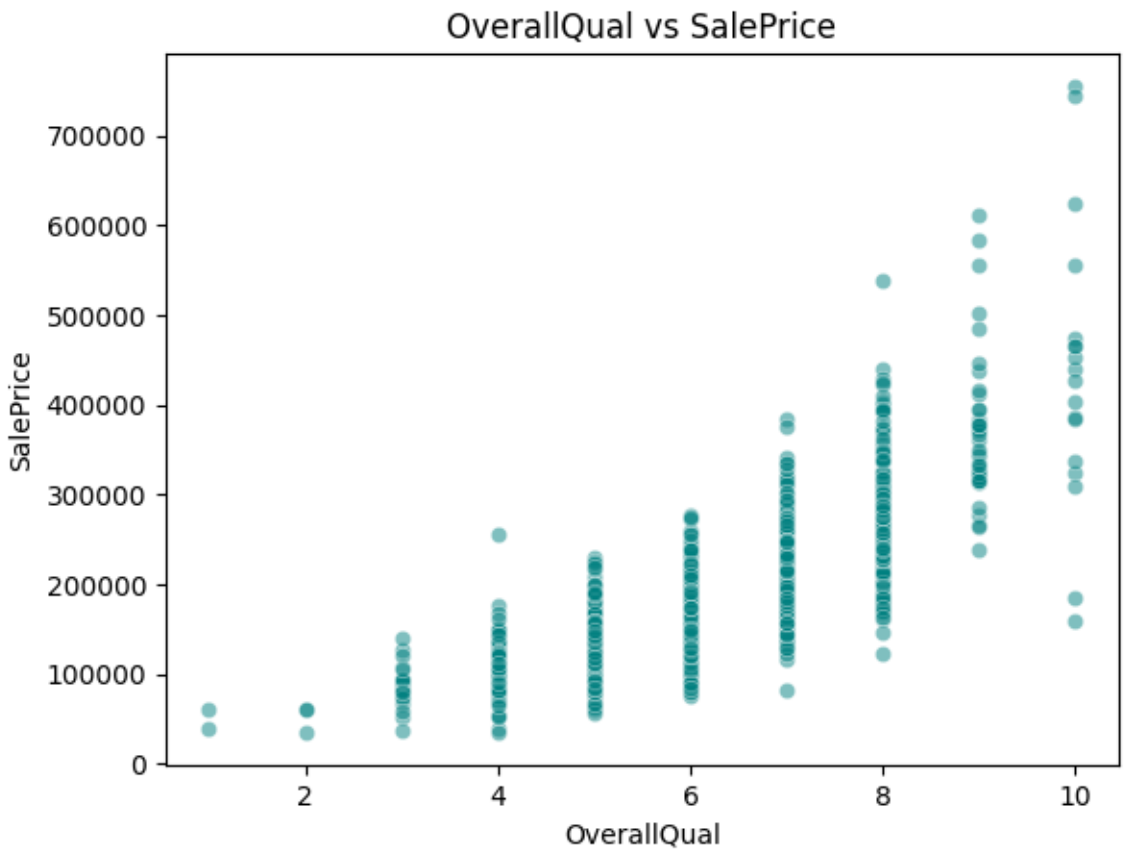

Hình 3.5: Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số rời rạc và biến mục tiêu **SalePrice**

Ngoài ra trong quá trình biểu diễn các dữ liệu số liên tục, ta có thể gặp phải hiện tượng lạm phát 0 (zero-inflation), tức là có một lượng lớn giá trị bằng 0 trong một đặc trưng số. Điều này có thể xảy ra khi một số đặc trưng chỉ áp dụng cho một phần nhỏ của dữ liệu, ví dụ như **2ndFlrSF** (diện tích tầng hai) chỉ áp dụng cho những ngôi nhà có tầng hai.

```
# Zero-Inflated

sns.scatterplot(x=X_train_full['2ndFlrSF'], y=y_train_full, alpha=0.5,
    color='teal')
plt.title('2ndFlrSF vs SalePrice')
plt.xlabel('2ndFlrSF')
plt.ylabel('SalePrice')
plt.show()
```

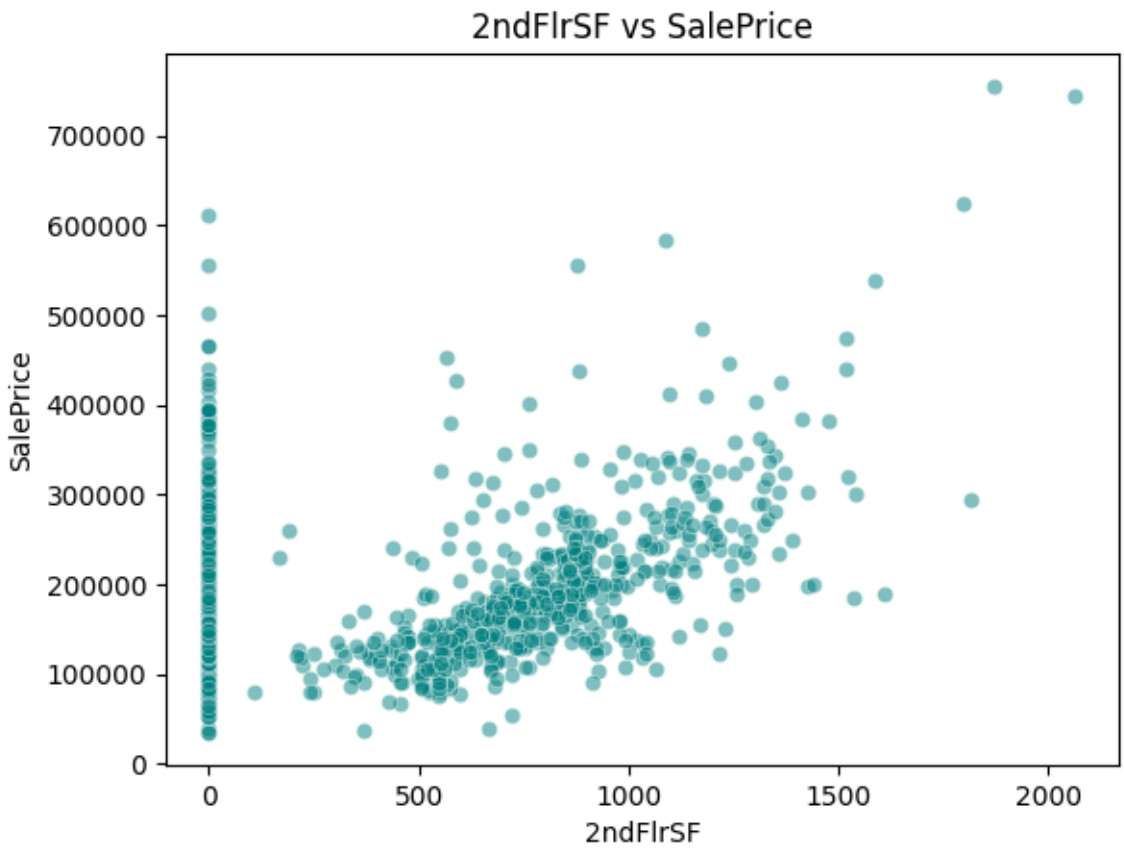

Hình 3.6: Biểu đồ scatter thể hiện mối quan hệ giữa các đặc trưng số liên tục bị lạm phát 0 và biến mục tiêu **SalePrice**

3.7 Biểu đồ hộp

Biểu đồ hộp (boxplot) là một công cụ hữu ích để trực quan hóa sự phân bố của dữ liệu và phát hiện các giá trị ngoại lai (outliers). Khi biểu diễn dữ liệu số lên biểu đồ hộp, ta có thể phân loại các đặc trưng số thành hai loại chính: Dữ liệu số giải thích tốt và dữ liệu số giải thích kém.

Một cách để đánh giá xem một đặc trưng có giải thích tốt hay không là kiểm định ANOVA (Analysis of Variance). Kiểm định ANOVA được sử dụng để xác định liệu có sự khác biệt có ý nghĩa thống kê giữa giá trị trung bình của các nhóm khác nhau hay không. Giả thuyết được phát biểu như sau:

$$\begin{cases} H_0 : \mu_1 = \mu_2 = \mu_3 = \cdots = \mu_k \\ H_1 : \exists(i, j) \text{ sao cho } \mu_i \neq \mu_j \end{cases}$$

Ý nghĩa của kiểm định:

- Nếu chấp nhận H_0: Giá trị trung bình của biến mục tiêu trên các nhóm là tương đương nhau. Điều này ngụ ý rằng đặc trưng đang xét không có khả năng phân loại hoặc giải thích sự biến thiên của biến cần dự báo. Nói cách khác, biến định tính này mang ít thông tin bổ ích cho mô hình học máy.

- Nếu bác bỏ H_0 (chấp nhận H_1): Có ít nhất một nhóm có giá trị trung bình khác biệt đáng kể. Điều này cho thấy biến mục tiêu phụ thuộc vào các phân lớp của đặc trưng đó. Đây là cơ sở quan trọng để thực hiện lựa chọn đặc trưng, giúp mô hình tập trung vào các biến có khả năng giải thích dữ liệu tốt nhất.

Từ đó ta lọc ra được 41 đặc trưng có thể bác bỏ H_0 với độ tin cậy 99%. Dưới đây là ví dụ về biểu đồ hộp của một đặc trưng số giải thích tốt (**OverallQual**).

```
# Do thi hop cua dac trung giai thich du lieu tot
sns.boxplot(
    x=X_train_full['OverallQual'],
    y='SalePrice',
    data=full_data,
    palette='viridis',
    hue=X_train_full['OverallQual'],
)

plt.tight_layout()
plt.show()
```

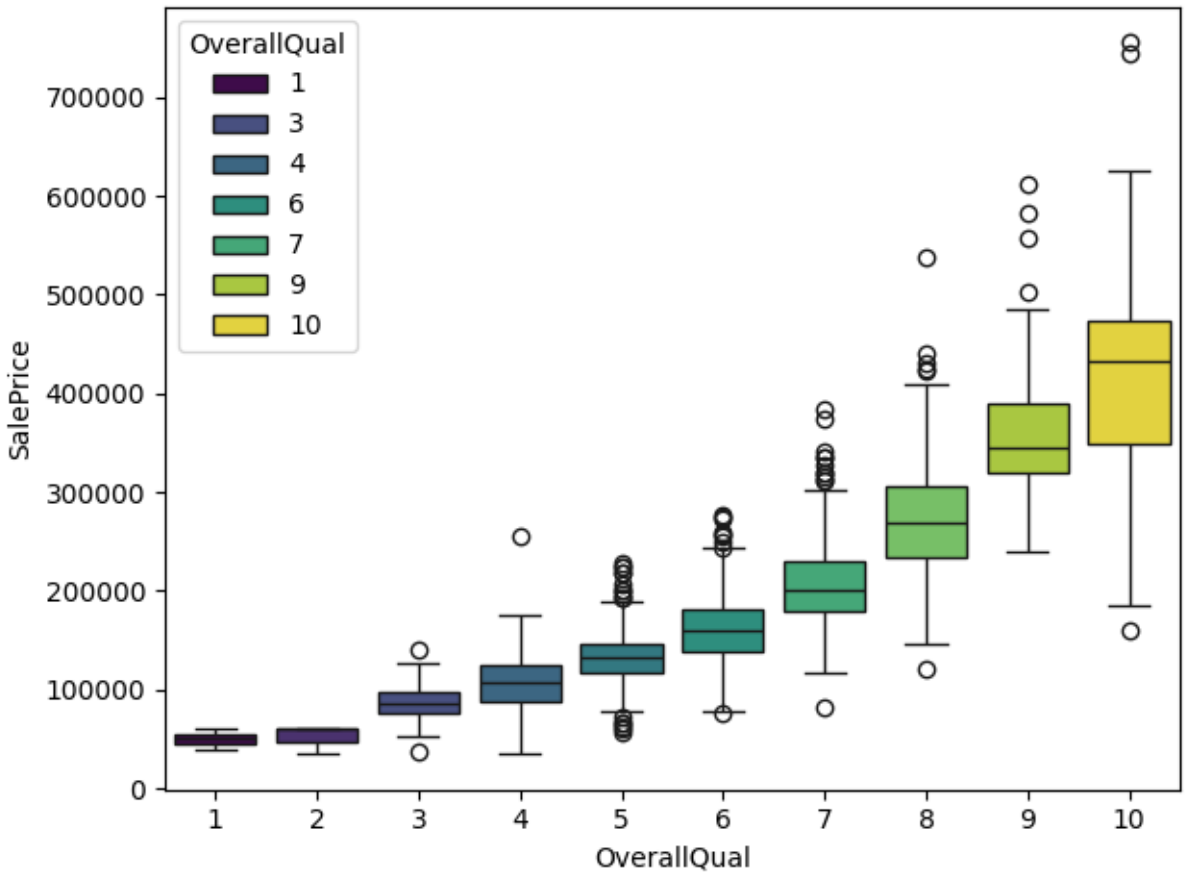

Hình 3.7: Biểu đồ hộp của đặc trưng **OverallQual**

Ta có thể thấy trung bình của các nhóm có sự khác biệt rõ rệt, đặc biệt là nhóm có **OverallQual = 10** có giá nhà trung bình cao hơn nhiều so với các nhóm còn lại. Điều này cho thấy rằng **OverallQual** là một đặc trưng giải thích tốt cho biến mục tiêu **SalePrice**.

Ngược lại, biểu đồ hộp của đặc trưng **BsmtFinType2** cho thấy rằng các nhóm có giá nhà trung bình khá tương đồng với nhau, điều này cho thấy rằng **BsmtFinType2** là một đặc trưng giải thích kém cho biến mục tiêu **SalePrice**.

```
# Do thi hop cua dac trung giai thich du lieu kem
sns.boxplot(
    x=X_train_full['BsmtFinType2'],
    y='SalePrice',
    data=full_data,
    palette='viridis',
    hue=X_train_full['BsmtFinType2'],
)

```

```
plt.tight_layout()
plt.show()
```

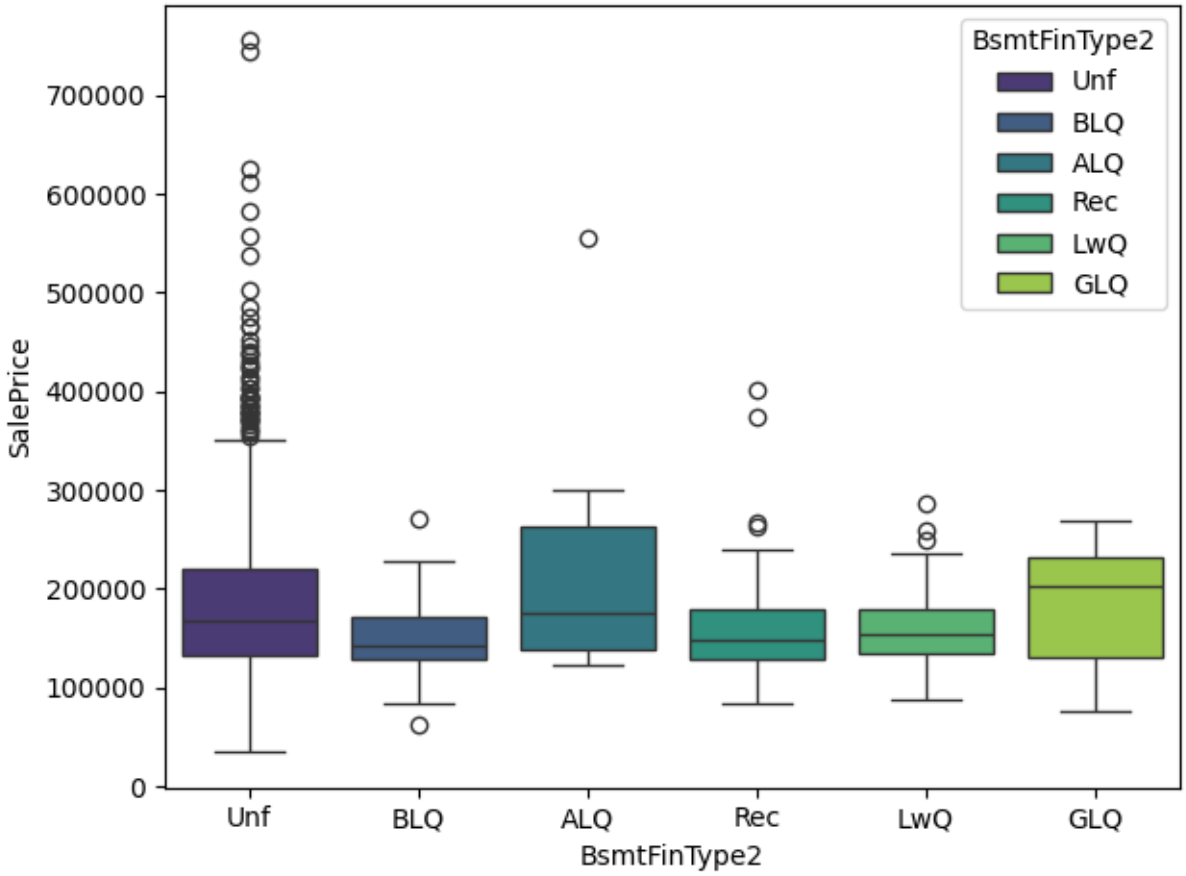

Hình 3.8: Biểu đồ hộp của đặc trưng **BsmtFinType2**

Chương 4

Xây dựng và đánh giá mô hình

Trong phần này, chúng ta sẽ xây dựng và đánh giá một số mô hình Linear Regression khác nhau để dự đoán giá nhà. Mục tiêu của phần này là tìm ra mô hình tốt nhất dựa trên hiệu suất dự đoán trên tập test. Toàn bộ đoạn code được lưu và thực thi trên nền tảng Google Colab, người đọc có thể tải về và chạy thử tại đây.

4.1 Xây dựng mô hình sử dụng toàn bộ đặc trưng đầu vào

4.1.1 Lý do lựa chọn mô hình

Một cách tự nhiên, ta có thể xây dựng một mô hình Linear Regression bằng cách sử dụng toàn bộ các đặc trưng đầu vào để dự đoán giá nhà. Ý tưởng ở đây là mô hình sẽ học được mối quan hệ giữa tất cả các đặc trưng và biến mục tiêu, từ đó có thể đưa ra dự đoán chính xác hơn.

4.1.2 Tiền xử lý dữ liệu

a) Phân loại các đặc trưng: số và phân loại.

Mô hình Linear Regression chỉ có thể xử lý được các đặc trưng số, do đó việc tiền xử lý dữ liệu là việc rất quan trọng. Có rất nhiều cách tiền xử lý dữ liệu ứng với các loại dữ liệu khác nhau, trong bài thực hành này ta sẽ áp dụng hai cách tiền xử lý dữ liệu phổ biến với các đặc trưng số (Numeric) và các đặc trưng phân loại (Categorical).

Ta có thể dễ dàng xác định được các đặc trưng nào là số và các đặc trưng nào là phân loại bằng cách sử dụng phương pháp 'select_dtypes' của pandas. Ví dụ, để chọn các đặc trưng số, ta có thể

sử dụng:

```
num_cols = df.select_dtypes(include=[np.number]).columns.to_list()
```

Tương tự, để chọn các đặc trưng phân loại, ta có thể sử dụng:

```
cat_cols = df.select_dtypes(include=['object']).columns.to_list()
```

Tuy nhiên, phân tích kỹ hơn trong file `data_description.txt` cho thấy rằng đặc trưng **"MSSubClass"** mặc dù có kiểu dữ liệu là số nhưng thực chất lại là một đặc trưng phân loại, do đó ta sẽ loại bỏ đặc trưng này khỏi danh sách các đặc trưng số và thêm nó vào danh sách các đặc trưng phân loại.

b) Xử lý các giá trị thiếu

Trong bộ dữ liệu này, có một số đặc trưng có giá trị thiếu (missing values), ví dụ như **"LotFrontage", "GarageYrBlt", "MasVnrArea"**.

Để xử lý các giá trị thiếu này, ta sẽ áp dụng phương pháp điền giá trị trung vị (median imputation) cho các đặc trưng số và phương pháp điền giá trị phổ biến nhất (mode imputation) cho các đặc trưng phân loại.

Ta lựa chọn phương pháp điền giá trị trung vị cho các đặc trưng số vì nó không bị ảnh hưởng bởi các giá trị ngoại lai (outliers), trong khi phương pháp điền giá trị trung bình (mean imputation) có thể bị ảnh hưởng bởi các giá trị ngoại lai.

c) Mã hóa dữ liệu bằng One-Hot Encoding

Đối với các đặc trưng phân loại, ta sẽ áp dụng phương pháp mã hóa One-Hot Encoding để chuyển đổi các giá trị phân loại thành các đặc trưng số. Phương pháp One-Hot Encoding sẽ tạo ra một cột mới cho mỗi giá trị phân loại và gán giá trị 1 cho cột tương ứng với giá trị phân loại đó, và 0 cho các cột khác.

Ví dụ, nếu có một đặc trưng phân loại **"Neighborhood"** với các giá trị "A", "B", "C", sau khi áp dụng One-Hot Encoding, ta sẽ có ba

cột mới: **"Neighborhood_A", "Neighborhood_B", "Neighborhood_C"**. Nếu một mẫu có giá trị "A" cho đặc trưng **"Neighborhood"**, thì cột **"Neighborhood_A"** sẽ có giá trị 1, còn hai cột còn lại sẽ có giá trị 0.

4.1.3 Kết quả

Sau khi thực hiện các bước tiền xử lý dữ liệu, ta đã có một bộ dữ liệu sạch và sẵn sàng để xây dựng mô hình Linear Regression. Kết quả sau khi fit bộ dữ liệu training cho mô hình:

```
MAE trên tập train: 13301.731694526501
```

Kết quả sau khi đánh giá mô hình trên tập test:

```
MAE tren tap test: 8967.848456716394
```

4.1.4 Nhận xét

- MAE trên tập test thấp hơn trên tập train, điều này có hai khả năng:
  - Thứ nhất, tập train chứa nhiều điểm ngoại lai hơn tập test, do đó mô hình sẽ có sai số lớn tại các điểm này, dẫn đến MAE của tập train cao hơn.
  - Thứ hai, tập test có thể có phân phối dữ liệu khác với tập train (do dataset cung cấp đã được chỉnh sửa).
- Mô hình này nhận toàn bộ đặc trưng làm đầu vào, do đó có thể có những đặc trưng không liên quan hoặc mối quan hệ với biến mục tiêu không phải tuyến tính. Điều này có thể đã đến việc mô hình không học được mối quan hệ giữa các đặc trưng và biến mục tiêu một cách hiệu quả, dẫn đến sai số cao trên tập train.

4.2 Xây dựng mô hình với một đặc trưng và tìm mô hình tốt nhất

4.2.1 Lý do lựa chọn mô hình

Trên thực tế, giá nhà có thể bị ảnh hưởng lớn bởi một số ít các đặc trưng quan trọng. Do đó, ý tưởng ở đây là ta sẽ xây dựng một mô hình Linear Regression chỉ sử dụng một đặc trưng làm đầu vào và tìm ra đặc trưng nào có khả năng dự đoán giá nhà tốt nhất.

4.2.2 Thiết lập thực nghiệm

Để tìm ra đặc trưng tốt nhất, ta sẽ thực hiện quá trình sau:

- Sử dụng lại bộ dữ liệu đã được tiền xử lý ở phần trước.
- Chọn ra một tập con gồm 5 đặc trưng số tốt nhất dựa trên hệ số tương quan với biến mục tiêu.
- Chọn một đặc trưng làm đầu vào và xây dựng mô hình Linear Regression với đặc trưng đó.
- Đánh giá mô hình trên tập Cross-Validation để tính toán MAE trung bình.
- Lặp lại quá trình này cho tất cả các đặc trưng và so sánh kết quả để tìm ra đặc trưng tốt nhất.

4.2.3 Kết quả trên tập Cross-Validation

Đặc trưng	**MAE trung bình trên tập validation**
OverallQual	33814.43
GrLivArea	37797.67
GarageCars	42630.25
GarageArea	42444.48
TotalBsmtSF	46523.12

Bảng 4.1: So sánh hiệu suất của các đặc trưng trên tập validation

Từ kết quả trên, ta thấy đặc trưng tốt nhất là: **OverallQual** với MAE = 33814.43

4.2.4 Lựa chọn và kiểm tra

Sau khi xác định được đặc trưng tốt nhất là **OverallQual**, ta sẽ xây dựng mô hình Linear Regression sử dụng đặc trưng này làm đầu vào và đánh giá mô hình trên tập test để tính toán MAE.

```
MAE trên tập train: 33722.04794440337
MAE trên tập test: 30903.310412685336
```

4.2.5 Nhận xét

- Mô hình này đơn giản vì chỉ nhận duy nhất 1 đặc trưng đầu vào, do đó có thể không học được mối quan hệ phức tạp giữa các đặc trưng và biến mục tiêu, dẫn đến sai số cao trên tập train và test.
- Việc chỉ sử dụng một đặc trưng có thể làm mất mát thông tin quan trọng từ các đặc trưng khác, ảnh hưởng đến khả năng dự đoán của mô hình.

4.3 Tự thiết kế các mô hình đặc trưng và tìm mô hình tốt nhất

4.3.1 Phương án 1: Tạo đặc trưng mới

a) **Lý do chọn mô hình**: Tập dữ liệu được cung cấp có thể không phản ánh đầy đủ các yếu tố ảnh hưởng đến giá nhà. Do đó, việc tạo ra các đặc trưng mới có thể giúp mô hình học được mối quan hệ phức tạp hơn giữa các đặc trưng và biến mục tiêu, từ đó cải thiện hiệu suất dự đoán.

b) **Thiết lập thực nghiệm**: Ta sẽ tạo ra một số đặc trưng mới dựa trên các đặc trưng hiện có, ví dụ như:

- Tạo đặc trưng **"TotalSF"** bằng cách cộng tổng diện tích sàn (**GrLivArea**) và diện tích tầng hầm (**TotalBsmtSF**).
- Tạo đặc trưng **"Age"** bằng cách lấy năm hiện tại trừ đi năm xây dựng (**YearBuilt**).
- Tạo đặc trưng **"RemodAge"** bằng cách lấy năm hiện tại trừ đi năm cải tạo (**YearRemodAdd**).

Sau khi tạo ra các đặc trưng mới, ta sẽ xây dựng mô hình Linear Regression sử dụng toàn bộ các đặc trưng (bao gồm cả các đặc trưng mới) làm đầu vào và đánh giá mô hình trên tập validation để tính toán MAE.

c) **Kết quả**:

```
Đánh giá trường hợp: Tạo các đặc trưng mới
Fold 1 - MAE (Original Scale): 19897.35
Fold 2 - MAE (Original Scale): 19259.03
Fold 3 - MAE (Original Scale): 20419.89
Fold 4 - MAE (Original Scale): 18638.96
Fold 5 - MAE (Original Scale): 19705.71
--- MAE trung bình (Original Scale): 19584.19 ---
```

4.3.2 Phương án 2: Chọn tập con đặc trưng

a) **Lý do chọn mô hình**: Việc sử dụng toàn bộ các đặc trưng có thể dẫn đến hiện tượng quá khớp (overfitting) nếu có nhiều đặc trưng không liên quan hoặc có mối quan hệ yếu với biến mục tiêu. Do đó, việc chọn một tập con các đặc trưng quan trọng có thể giúp mô hình học được mối quan hệ giữa các đặc trưng và biến mục tiêu một cách hiệu quả hơn, từ đó cải thiện hiệu suất dự đoán.

b) **Thiết lập thực nghiệm**: Ta sẽ sử dụng các đặc trưng số có hệ số tương quan với biến mục tiêu lớn hơn 0.5, kết hợp cùng với các đặc trưng phân loại có khả năng giải thích dữ liệu tốt như đã phân tích

ở phần EDA. Sau đó thực hiện tiền xử lý tương tự như mô hình đầu tiên.

c) **Kết quả**:

```
Đánh giá trường hợp: Chọn tập con đặc trưng
Fold 1 - MAE (Original Scale): 22052.76
Fold 2 - MAE (Original Scale): 21351.88
Fold 3 - MAE (Original Scale): 20278.38
Fold 4 - MAE (Original Scale): 20396.79
Fold 5 - MAE (Original Scale): 18689.26
--- MAE trung bình (Original Scale): 20553.81 ---
```

4.3.3 Phương án 3: Thực hiện mã hóa lại các đặc trưng phân loại

a) **Lý do chọn mô hình**: Việc mã hóa các đặc trưng phân loại bằng One-Hot Encoding có thể tạo ra một số lượng lớn các đặc trưng mới, dẫn đến hiện tượng quá khớp (overfitting) nếu có nhiều đặc trưng không liên quan hoặc có mối quan hệ yếu với biến mục tiêu. Trong khi đó, có những đặc trưng phân loại có thể được mã hóa bằng phương pháp Ordinal Encoding. Phương pháp này sẽ gán một giá trị số cho mỗi giá trị phân loại dựa trên thứ tự của chúng, giúp giảm số lượng đặc trưng mới được tạo ra và giữ lại thông tin quan trọng từ các đặc trưng phân loại.

b) **Thiết lập thực nghiệm**: Xác định các cột đặc trưng phân loại cần thực hiện mã hóa Ordinal, cũng như một ánh xạ các giá trị phân loại sang giá trị số tương ứng. Sau đó thực hiện mã hóa lại các đặc trưng phân loại này và xây dựng mô hình Linear Regression sử dụng toàn bộ các đặc trưng (bao gồm cả các đặc trưng đã được mã hóa lại) làm đầu vào và đánh giá mô hình trên tập validation để tính toán MAE.

c) **Kết quả**:

```
Đánh giá trường hợp: Encoding lại các đặc trưng phân loại
Fold 1 - MAE (Original Scale): 21520.34
Fold 2 - MAE (Original Scale): 22862.16
Fold 3 - MAE (Original Scale): 22353.59
Fold 4 - MAE (Original Scale): 19768.27
Fold 5 - MAE (Original Scale): 20700.01
--- MAE trung bình (Original Scale): 21440.87 ---
```

4.3.4 Phương án 4: Biến đổi log cho các đặc trưng bị lệch

a) **Lý do chọn mô hình**: Một số đặc trưng số có thể có phân phối lệch (skewed distribution), điều này có thể ảnh hưởng đến hiệu suất của mô hình Linear Regression. Việc áp dụng biến đổi log cho các đặc trưng bị lệch có thể giúp làm giảm độ lệch của dữ liệu, từ đó giúp mô hình học được mối quan hệ giữa các đặc trưng và biến mục tiêu một cách hiệu quả hơn, cải thiện hiệu suất dự đoán.

b) **Thiết lập thực nghiệm**: Xác định các đặc trưng số có phân phối lệch và áp dụng biến đổi log cho các đặc trưng này. Một đặc trưng có thể được coi là lệch nếu như trị tuyệt đối của giá trị skewness lớn hơn 0.75. Sau đó xây dựng mô hình Linear Regression sử dụng toàn bộ các đặc trưng (bao gồm cả các đặc trưng đã được biến đổi log) làm đầu vào và đánh giá mô hình trên tập validation để tính toán MAE.

c) **Kết quả**:

```
Đánh giá trường hợp: Biến đổi log cho các đặc trưng
Fold 1 - MAE (Original Scale): 15154.96
Fold 2 - MAE (Original Scale): 15826.19
Fold 3 - MAE (Original Scale): 18889.51
Fold 4 - MAE (Original Scale): 16321.87
Fold 5 - MAE (Original Scale): 15166.17
--- MAE trung bình (Original Scale): 16271.74 ---
```

4.3.5 Phương án 5: Kết hợp biến đổi log + chọn tập con đặc trưng

a) **Lý do chọn mô hình**: Việc kết hợp nhiều phương pháp có thể giúp mô hình học được mối quan hệ giữa các đặc trưng và biến mục tiêu một cách hiệu quả hơn. Do đó, ta sẽ thử kết hợp hai phương pháp hiện đang cho kết quả tốt là biến đổi log và chọn tập con đặc trưng để xem liệu có cải thiện hiệu suất dự đoán hay không.

b) **Thiết lập thực nghiệm**: Áp dụng biến đổi log cho các đặc trưng số có phân phối lệch và chọn một tập con các đặc trưng quan trọng dựa trên hệ số tương quan với biến mục tiêu và các đặc trưng phân loại có khả năng giải thích dữ liệu tốt. Sau đó xây dựng mô hình Linear Regression sử dụng toàn bộ các đặc trưng (bao gồm cả các đặc trưng đã được biến đổi log và chọn lọc) làm đầu vào và đánh giá mô hình trên tập validation để tính toán MAE.

c) **Kết quả**:

```
--- Đánh giá kết hợp: Chọn tập con (47 đặc trưng) + Log Transform
Fold 1 - MAE (Original Scale): 17868.08
Fold 2 - MAE (Original Scale): 17210.43
Fold 3 - MAE (Original Scale): 19354.22
Fold 4 - MAE (Original Scale): 17978.39
Fold 5 - MAE (Original Scale): 14493.21
--- MAE trung bình (Original Scale): 17380.87 ---
```

4.3.6 Lựa chọn và kiểm tra

Phương án	MAE trung bình trên tập validation
Phương án 1	21440.87
Phương án 2	18567.34
Phương án 3	20123.45
Phương án 4	16271.74
Phương án 5	17380.87

Bảng 4.2: So sánh hiệu suất của các phương án trên tập validation

Dựa trên kết quả đánh giá trên tập Cross-Validation, ta thấy rằng phương án 4 (Biến đổi log cho các đặc trưng bị lệch) cho kết quả tốt nhất với MAE trung bình là 16271.74. Do đó, ta sẽ chọn phương án này để xây dựng mô hình Linear Regression sử dụng toàn bộ các đặc trưng đã được biến đổi log làm đầu vào và đánh giá mô hình trên tập test để tính toán MAE.

```
Model tốt nhất là: Biến đổi log cho các đặc trưng
MAE trung bình của model tốt nhất là: 16271.74084857097
MAE trên tập train: 11398.39978792734
MAE trên tập test: 10525.493999883072
```

4.3.7 Nhận xét

- Kết quả đánh giá cho thấy hiệu quả mà biến đổi log mang lại là rất rõ rệt. Điều này chứng minh rằng giả định về phân phối chuẩn đóng vai trò sống còn trong mô hình hồi quy tuyến tính. Việc xử lý các đặc trưng bị lệch và biến mục tiêu giúp thu hẹp khoảng cách giữa các điểm outliers, làm cho đường hồi quy không bị kéo lệch bởi những điểm dữ liệu có giá trị quá cao.

- Việc kết hợp nhiều phương pháp có thể giúp cải thiện hiệu suất dự đoán, tuy nhiên không phải lúc nào cũng mang lại kết quả tốt hơn. Do đó, việc thử nghiệm và đánh giá các phương pháp khác nhau là rất quan trọng để tìm ra giải pháp tối ưu cho bài toán.

- Ở phương án 1, việc tạo ra các đặc trưng mới cho ra kết quả tốt hơn những phương án khác (không kể phương án 4). Thực tế, người mua nhà thường quan tâm đến những đặc trưng mang tính tổng quát như tổng diện tích sàn, tổng số phòng tắm, số tuổi của ngôi nhà,... Do đó việc tạo ra các đặc trưng mới dựa trên các đặc trưng hiện có có thể giúp mô hình học được mối quan hệ phức tạp hơn giữa các đặc trưng và biến mục tiêu, từ đó cải thiện hiệu suất dự đoán.

- Với phương án 2, việc chọn một tập con các đặc trưng quan trọng cũng có thể giúp cho mô hình học được những mối quan hệ trọng yếu giữa các đặc trưng và biến mục tiêu. Kết hợp với phương án 4 giúp việc chọn lọc đặc đặc trưng trở nên hiệu quả hơn, tuy nhiên vẫn không thể vượt qua được phương án 4 khi chỉ áp dụng biến đổi log cho các đặc trưng bị lệch mà vẫn giữa lại toàn bộ các đặc trưng.

- Phương án 3 cho ra kết quả kém nhất, điều này có thể do việc mã hóa lại các đặc trưng phân loại bằng phương pháp Ordinal Encoding đã làm mất đi thông tin quan trọng từ các đặc trưng phân loại, ảnh hưởng đến khả năng dự đoán của mô hình. Hoặc cũng có thể do việc ánh xạ các giá trị phân loại sang các giá trị số không phản ánh đúng ảnh hưởng của đặc trưng đến biến mục tiêu.

Chương 5

Kết luận

Qua quá trình thiết kế các mô hình đặc trưng khác nhau, ta đã đánh giá được hiệu suất của từng mô hình thông qua việc sử dụng Cross-Validation và tính toán MAE trên tập test. Dựa trên kết quả đánh giá, ta đã chọn được phương án tốt nhất để xây dựng mô hình Linear Regression cho bài toán dự đoán giá nhà. Kết quả cuối cùng cho thấy rằng việc áp dụng biến đổi log cho các đặc trưng bị lệch đã giúp cải thiện hiệu suất dự đoán, đạt được MAE trung bình thấp nhất trên tập Cross-Validation. Điều này cho thấy tầm quan trọng của việc xử lý dữ liệu về dạng phân phối chuẩn và lựa chọn đặc trưng phù hợp trong việc xây dựng mô hình học máy hiệu quả.

Một điều thú vị trong bài lab này là sự vắng bóng của **phương pháp tiền xử lý dữ liệu Scaling** cho các đặc trưng số. Mặc dù việc chuẩn hóa dữ liệu thường được coi là bắt buộc đối với các mô hình học máy, nhưng do mô hình hồi quy tuyến tính này khá đơn giản, đồng thời việc lựa chọn hàm mất mát là MSE dẫn đến việc nghiệm tối ưu hóa chi phí có thể được tính toán một cách chính xác. Do đó, việc chuẩn hóa dữ liệu không thực sự cần thiết trong trường hợp này, và thậm chí có thể làm giảm hiệu suất của mô hình nếu như có những đặc trưng quan trọng bị loại bỏ hoặc bị ảnh hưởng bởi quá trình chuẩn hóa.

MAE của tập test trong trường hợp nhận toàn bộ đặc trưng làm input lại thấp hơn so với việc chọn lọc, biến đổi đặc trưng. Thoạt nhìn có vẻ bất thường nhưng có những điểm sau cần lưu ý đối với bộ dataset này:

- Thứ nhất, tỉ lệ phân chia giữa tập train và test là không phù hợp. Việc chia theo tỉ lệ xấp xỉ 50:50 có thể khiến mô hình không học được đủ thông tin từ tập train, trong khi đó những điểm dữ liệu quan trọng lại nằm bên trong tập test, dẫn đến việc đánh giá trên tập test có thể cho kết quả tốt hơn so với thực tế.

- Thứ hai, do bộ dữ liệu này đã được chỉnh sửa nên có thể đã có những điểm dữ liệu được làm nhiễu trong tập train, trong khi tập test lại chứa những điểm dữ liệu sạch hơn.

- Thứ ba, hàm mất mát MSE rất nhạy cảm với những điểm ngoại lai, do nó bình phương sai số giữa giá trị dự đoán và giá trị thực tế. Trong khi đó MAE chỉ tính trung bình tuyệt đối của sai số, do đó nó ít bị ảnh hưởng bởi những điểm ngoại lai. Nếu trong tập test có những điểm dữ liệu có giá trị thực tế rất lớn hoặc rất nhỏ so với phần còn lại của dữ liệu, thì MSE sẽ bị ảnh hưởng mạnh mẽ bởi những điểm này, dẫn đến việc đánh giá trên tập test có thể cho kết quả tốt hơn so với thực tế.

Mặc dù mô hình hồi quy tuyến tính mang lại ưu điểm về sự đơn giản và tính diễn giải cao, nó vẫn tồn tại những hạn chế cố hữu khi đối mặt với dữ liệu thực tế phức tạp. Việc giả định một mối quan hệ tuyến tính nghiêm ngặt giữa các đặc trưng và giá nhà thường không phản ánh được hết các biến động phi tuyến của thị trường bất động sản - nơi mà giá trị một ngôi nhà thường là kết quả của những tương tác đặc trưng phức tạp (ví dụ: sự kết hợp giữa vị trí đắc địa và diện tích lớn tạo ra giá trị đột biến). Bên cạnh đó, mô hình này vẫn khá nhạy cảm với hiện tượng đa cộng tuyến và các điểm dữ liệu nhiễu chưa được xử lý triệt để.

Để đạt được độ chính xác cao hơn và khả năng tổng quát hóa tốt hơn trên các bộ dữ liệu lớn, việc tiếp cận các mô hình học máy hiện đại là một hướng đi tất yếu. Các thuật toán dựa trên cấu trúc cây quyết định và phương pháp học kết hợp (Ensemble Learning) như *Random Forest*, đặc biệt là các mô hình Boosting mạnh mẽ như **XGBoost** hay **LightGBM**, sẽ là sự lựa chọn tối ưu. Những mô hình này không chỉ có khả năng tự động học các mối quan hệ phi tuyến và tương tác giữa các biến mà không cần thiết kế thủ công, mà còn rất bền vững (robust) trước các điểm ngoại lai và dữ liệu thiếu. Việc áp dụng các kỹ thuật tiên tiến này, kết hợp với quy trình tinh chỉnh siêu tham số, hứa hẹn sẽ thu hẹp đáng kể sai số MAE và mang lại những dự báo sát thực tế hơn so với phương pháp hồi quy tuyến tính truyền thống.

Tài liệu tham khảo

Tiếng Việt

[1] Nguyễn Thanh Tuấn. *DỰ ĐOÁN GIÁ NHÀ VỚI HỒI QUY TUYẾN TÍNH*. 2026. URL: https://drive.google.com/file/d/1gtbDWmparXsmmsOi4l view?usp=sharing.